

Informe técnico final: pipeline de IA para predicción y segmentación de demanda

Caso SITP / TransMilenio — Portal Eldorado

Estudiante:	Oscar Fabián Pedraza García (trabajo individual)
Docente:	Ph.D. Jhony Andrés Guzmán Henao
Repositorio:	github.com/oscar176/Master

1. Problema organizacional

El Portal Eldorado del SITP/TransMilenio concentra un volumen de salida de personas muy desigual entre sus cinco accesos y a lo largo del día: un solo acceso mueve más de la mitad del flujo total, y existe una franja de la mañana claramente más cargada que el resto. Hoy la asignación de personal, capacidad y señalización se decide con criterio general, sin un mecanismo sistemático que anticipe cuándo y dónde se concentrará la demanda, ni que agrupe los patrones de uso recurrentes para diferenciar la respuesta operativa entre accesos. Este proyecto responde a esa brecha para el equipo de operación de la estación —quien planea turnos y gestiona accesos—, con dos preguntas de negocio concretas: ¿se puede anticipar, con datos de calendario y de acceso, si una franja horaria será de alta demanda, con antelación suficiente para reforzar personal? Y ¿qué combinaciones de acceso y franja comparten un perfil de uso similar, y qué acción operativa distinta amerita cada una?

2. Datos y proceso ETL

La fuente es el registro de salidas por acceso e intervalo de 15 minutos de Portal Eldorado, noviembre de 2023 (TRANSMILENIO S.A. / Datos Abiertos Bogotá, licencia CC BY 4.0). Este entorno no tiene acceso directo al portal oficial, por lo que la muestra se transcribió manualmente — limitación que se declara aquí y en el notebook, no se oculta. El archivo crudo (452 filas, formato ancho) nunca se modifica: todo el procesamiento genera archivos nuevos. El ETL aplicado: (1) corrección documentada de caracteres mal codificados; (2) exclusión de 2 accesos con extracción incompleta en este entorno (9 filas), quedando 443 filas de los 5 accesos con extracción completa; (3) transformación de formato ancho a largo (13.290 filas: acceso × intervalo × día); (4) parseo de separadores de miles en formato colombiano; (5) detección de atípicos por rango intercuartílico (IQR), calculado por acceso e intervalo, no de forma global. Resultado: 0 duplicados, 2,68 % de observaciones atípicas —marcadas, no eliminadas— y un archivo depurado (sitp_portal_eldorado_depurado.csv) que acompaña esta entrega.

3. Análisis exploratorio (EDA)

Indicador	Valor
Total de salidas registradas (noviembre 2023)	879.772
Participación del acceso Túnel PLAT1	53,0 % del total (top 1 de 5 accesos)
Promedio entre semana vs. fin de semana	73,8 vs. 45,2 salidas/franja (+63 %)
Franja de mayor salida promedio	07:45 a. m.

Estos cuatro indicadores, junto con tres visualizaciones (perfil horario, participación por acceso y comparación semana/fin de semana), muestran un patrón consistente: la demanda no se reparte de forma pareja ni por acceso, ni por hora, ni por día — se concentra. Esa concentración es lo que los dos modelos de la sección siguiente intentan anticipar (predicción) y estructurar en grupos accionables (segmentación).

4. Modelos de machine learning (vs. línea base)

4.1 Supervisado — árbol de decisión (¿será una franja de "alta demanda"?)

Modelo	Exactitud	Frente a línea base	Clase "alta demanda"
Línea base (siempre "no alta demanda")	72,18 %	—	precisión/recall/F1 = 0 / 0 / 0
Árbol de decisión (max_depth = 5)	84,06 %	+11,88 pp	prec. 0,757 · recall 0,629 · F1 0,687

El árbol predice si una franja estará en el 25 % de mayor salida dentro de su propio acceso (evita el atajo de aprender solo el acceso), con separación entrenamiento/prueba por fecha —no aleatoria— para simular una predicción real a futuro. La mejora sobre la línea base es real (+11,88 puntos), pero un recall de 62,9 % significa que 193 de 520 picos reales de la semana de prueba no se detectan: la matriz de confusión importa más que la exactitud sola. Variable más influyente: la hora del día (importancia 0,457), seguida de si el acceso es el Túnel PLAT1 (0,344). Un árbol sin límite de profundidad llega a 88,71 % pero con 114 hojas (vs. 18) y mayor brecha entrenamiento-prueba; se prefiere el árbol interpretable.

4.2 No supervisado — K-Means (¿qué combinaciones acceso/franja se parecen?)

k (grupos)	2	3	4 (elegido)	5	6
Índice de silueta	0,312	0,348	0,361	0,384*	0,343

*k = 5 da mayor silueta pero con dos grupos casi vacíos (12 y 5 combinaciones); se prefiere k = 4 por producir segmentos con tamaño operativamente útil. Con k = 4 (silueta 0,361 — estructura moderada, declarada así, no maquillada) aparecen tres grupos accionables —franjas fuertes entre semana (107 combinaciones, ~112 salidas/franja, accesos 03/04/21), meseta de tarde/noche (192 combinaciones, repartida parejo en los 5 accesos) y valle de bajo volumen (139 combinaciones, accesos de baja afluencia)— y un cuarto grupo de apenas 5 combinaciones (1,1 %) que se trata explícitamente como ruido, no como segmento de negocio.

5. Hallazgos, recomendaciones y limitaciones

Hallazgos

- La demanda está fuertemente concentrada: un acceso (Túnel PLAT1) y una franja (07:45 a. m.) explican una parte desproporcionada del flujo total.
- La hora del día predice mejor la alta demanda que el acceso por sí solo (importancia 0,457 vs. 0,344).
- Existen 3 patrones de uso recurrentes genuinos (mañana entre semana, tarde/noche pareja, valle de bajo volumen) y 1 grupo residual que no debe tratarse como segmento real.

Recomendaciones

- Reforzar personal en los accesos 03, 04 y 21 en las franjas de mañana entre semana — el segmento de mayor volumen absoluto.
- Mantener personal distribuido de forma pareja entre los 5 accesos durante la meseta de tarde/noche — es un fenómeno de toda la estación, no de un acceso puntual.
- Consolidar turnos en los accesos 18 y 19 donde el volumen lo justifique, sin reducir su servicio de accesibilidad por debajo de un mínimo operativo.
- Usar el árbol como alerta de apoyo para quien programa turnos — no como disparador automático de decisiones de personal.

Limitaciones

- Un solo mes de datos (noviembre de 2023); no se ha validado contra otra temporada del año.
- Los accesos 18 y 19 quedaron fuera del modelo supervisado (su volumen casi nulo degenera el umbral estadístico de "alta demanda").
- Silueta moderada (0,361): las fronteras entre grupos no son nítidas, hay traslape visible.
- Recall de 62,9 % en la clase de interés: el modelo aún deja pasar picos reales.
- Muestra transcrita manualmente, no descargada directamente del portal oficial.

6. Reflexión ética sobre el uso de datos y de IA

El dataset es información agregada de conteos por estación, sin datos personales identificables, publicada bajo licencia abierta (CC BY 4.0) y correctamente atribuida a TRANSMILENIO S.A. / Datos Abiertos Bogotá. Aun así, el proyecto involucra al menos tres decisiones con implicación ética directa. Primera, la transparencia sobre el origen de los datos: al no tener este entorno acceso directo al portal oficial, la muestra se transcribió manualmente. Presentarla como si fuera una descarga automática sería engañoso; declararlo explícitamente —aquí y en el notebook— fue la postura sostenida en todo el proyecto. Segunda, la equidad hacia los accesos de baja afluencia: los accesos (18) y (19), de uso prioritario para personas con discapacidad, quedaron fuera del modelo supervisado porque su volumen casi nulo hace que cualquier umbral estadístico pierda sentido. Esa es una decisión técnica correcta, pero conlleva un riesgo ético si se traduce mecánicamente en abandono operativo: que un acceso no tenga modelo predictivo no significa que deba tener menos prioridad de servicio, por eso la recomendación es consolidar turnos donde el volumen lo justifique y no reducir el servicio de accesibilidad. Tercera, el uso responsable de modelos imperfectos: declarar una silueta de 0,361 como moderada en vez de presentarla como una segmentación nítida, y declarar que el árbol deja pasar el 37 % de los picos reales en vez de mostrar solo la exactitud, son decisiones deliberadas de este informe. Un modelo que subestima su propia incertidumbre puede llevar a decisiones de personal mal calibradas, con impacto real en las condiciones de trabajo de quienes son reasignados de turno. Por eso ambos modelos se recomiendan como apoyo a la decisión humana, con revisión, y no como reemplazo de ella.

7. Declaración de uso de herramientas de IA

Este proyecto se desarrolló con apoyo de Claude (Anthropic) como asistente de IA a lo largo de las entregas del caso SITP/Portal Eldorado. El asistente participó en la redacción y depuración del código de ETL, EDA y modelado bajo mi dirección, en la ejecución y validación del notebook, y en la redacción de borradores de este informe y de las celdas de interpretación, a partir de resultados que yo definí, verifiqué y aprobé. Las decisiones de fondo —la pregunta de negocio, el diseño del target y las variables, la elección de los modelos y el juicio profesional sobre su puesta en producción— fueron mías, revisadas antes de esta entrega. No se compartió con la herramienta ningún dato personal más allá del propio dataset público y agregado.

Entregables complementarios: notebook ejecutado (Notebook_Pipeline_IA_SITP_PortalEldorado.ipynb), archivo de datos depurado, registro de ejecución, dashboard (Power BI) y presentación — ver repositorio de GitHub.